MVP Análise de Dados e Boas Práticas

Identificação:

- **Nome:** Rodolpho Mallmann Hruby
- **Matrícula:** 4052025001472
- **Dataset:** [IBM HR Analytics Employee Attrition & Performance - Kaggle]

Descrição do Problema e Objetivo Principal

No atual cenário corporativo, a retenção de talentos é um dos maiores desafios do setor de Recursos Humanos (People Analytics). A alta rotatividade (*attrition*) gera custos expressivos com rescisões, recrutamento, integração de novos colaboradores e perda de capital intelectual. O conjunto de dados escolhido na Kaggle, *IBM HR Analytics Employee Attrition*, traz informações detalhadas sobre o perfil dos colaboradores de uma organização.

Visto isso, o **objetivo principal** desta análise é explorar e identificar os principais fatores e padrões que levam à rotatividade, além de preparar os dados para que, no futuro, um modelo preditivo possa classificar quais funcionários têm maior probabilidade de deixar a empresa.

Hipóteses do Problema

Após o entendimento da problemática principal do cenário, levantarei as seguintes hipóteses na análise exploratória:

1. **Financeiro:** Funcionários com menor Renda Mensal (*Monthly Income*) e menor percentual de aumento salarial (*PercentSalaryHike*) apresentam maior taxa de saída da empresa?
2. **Desgaste (Work-life Balance):** A realização constante de Horas Extras (*OverTime*) combinada com longas distâncias de casa para o trabalho (*DistanceFromHome*) aumenta a probabilidade de um funcionário deixar a organização?

3. **Demográfica e de Carreira:** Colaboradores mais jovens (*Age*) e com menos tempo no cargo atual (*YearsInCurrentRole*) procuram mais oportunidades fora da empresa em comparação aos veteranos estabilizados?

Tipo de Problema

Trato desse um problema de **Classificação Binária** enquadrado no paradigma de Aprendizagem Supervisionada. O objetivo é prever uma variável alvo (*target*) categórica com duas classes possíveis: se o funcionário vai sair da empresa (`Attrition = Yes`) ou se vai permanecer (`Attrition = No`).

Seleção de Dados

O *dataset* foi selecionado e extraído diretamente da plataforma Kaggle. Após a primeira busca, identifiquei uma certa excelência na qualidade dos dados (ausência de nulos estruturais) e pela rica diversidade de variáveis contínuas, discretas e categóricas, compondo um cenário ideal para aplicar técnicas de pré-processamento, análise exploratória aprofundada e responder a problemas reais de negócios que foram levantadas nas minhas hipóteses

Atributos do Dataset

Data Set Characteristics:

```
:Number of Instances: 1470
:Number of Attributes: 34 predictive attributes and the class
:Attribute Information:
    - Age (numeric)
    - BusinessTravel (categorical)
    - DailyRate (numeric)
    - Department (categorical)
    - DistanceFromHome (numeric - miles)
    - Education (numeric - 1 'Below College' to 5 'Doctor' )
    - EducationField (categorical)
    - EmployeeCount (numeric)
```

```
    - EmployeeNumber (numeric)
    - EnvironmentSatisfaction (numeric - 1 'Low' to 4 'Very High')
    - Gender (categorical)
    - HourlyRate (numeric)
    - JobInvolvement (numeric - 1 'Low' to 4 'Very High')
    - JobLevel (numeric - 1 to 5)
    - JobRole (categorical)
    - JobSatisfaction (numeric - 1 'Low' to 4 'Very High')
    - MaritalStatus (categorical)
    - MonthlyIncome (numeric - dollars)
    - MonthlyRate (numeric)
    - NumCompaniesWorked (numeric)
    - Over18 (categorical)
    - OverTime (categorical)
    - PercentSalaryHike (numeric - percentage)
    - PerformanceRating (numeric - 3 'Excellent' to 4 'Outstanding')
    - RelationshipSatisfaction (numeric - 1 'Low' to 4 'Very High')
    - StandardHours (numeric)
    - StockOptionLevel (numeric - 0 to 3)
    - TotalWorkingYears (numeric)
    - TrainingTimesLastYear (numeric)
    - WorkLifeBalance (numeric - 1 'Bad' to 4 'Best')
    - YearsAtCompany (numeric)
    - YearsInCurrentRole (numeric)
    - YearsSinceLastPromotion (numeric)
    - YearsWithCurrManager (numeric)

    - class:
            - Yes (Attrition - Funcionário saiu)
            - No (Attrition - Funcionário permaneceu)

:Missing Attribute Values: None
```

```
:Class Distribution: 237 - Yes (Attrition), 1233 - No (Attrition)
:Creator: IBM Data Scientists
:Donor: Pavan Subhash (via Kaggle)
```

Importação de Bibliotecas e Carga de Dados

Nesta célula, importarei as bibliotecas necessárias para manipulação de dados, visualizações gráficas e todas as ferramentas do `scikit-learn` para transformações matemáticas e prepar para modelos de Machine Learning.

```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
import missingno as msno
import kagglehub
import warnings

# Imports do Scikit-Learn
from sklearn.model_selection import train_test_split, KFold, cross_val_score
from sklearn.preprocessing import MinMaxScaler, StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
from sklearn.neighbors import KNeighborsClassifier
from sklearn.naive_bayes import GaussianNB
from sklearn.svm import SVC
from sklearn.ensemble import BaggingClassifier, RandomForestClassifier, ExtraTreesClassifier, AdaBoostClassifier, Gradi
from sklearn.pipeline import Pipeline

warnings.filterwarnings('ignore')

# Download e Carga dos Dados via Kagglehub (Também há como disponibilziar o arquivo via GitHub, porém optei por exporta
path = kagglehub.dataset_download("pavansubhasht/ibm-hr-analytics-attrition-dataset")
df = pd.read_csv(f"{path}/WA_Fn-UseC_-HR-Employee-Attrition.csv")
```

```
Downloading to /root/.cache/kagglehub/datasets/pavansubhasht/ibm-hr-analytics-attrition-dataset/1.archive...
100%|██████████| 50.1k/50.1k [00:00<00:00, 13.6MB/s]Extracting files...
```

Análise de Dados Exploratória (EDA)

Na Análise Exploratória de Dados, busco inspecionar as características primárias do *dataset*. Ire verificar as primeiras linhas, a dimensionalidade e os tipos de dados alocados em cada coluna.

```
display(df.head())
print("\n--- Informações do Dataset ---")
print(f"Total de Instâncias (Linhas): {df.shape[0]}")
print(f"Total de Atributos (Colunas): {df.shape[1]}\n")
df.info()
```

	Age	Attrition	BusinessTravel	DailyRate	Department	DistanceFromHome	Education	EducationField	EmployeeCount
0	41	Yes	Travel_Rarely	1102	Sales	1	2	Life Sciences	1
1	49	No	Travel_Frequently	279	Research & Development	8	1	Life Sciences	1
2	37	Yes	Travel_Rarely	1373	Research & Development	2	2	Other	1
3	33	No	Travel_Frequently	1392	Research & Development	3	4	Life Sciences	1
4	27	No	Travel_Rarely	591	Research & Development	2	1	Medical	1

5 rows × 35 columns

Entendimento sobre a EDA: A inspeção inicial via `df.info()` revelou que não possui valores nulos aparentes e que os tipos de dados estão corretamente divididos entre `int64` (variáveis numéricas) e `object` (variáveis categóricas). Variáveis como `EmployeeCount` e `StandardHours` parecem ter um único valor para todas as linhas, o que será tratado no pré-processamento.

```
--- Informações do Dataset ---
Total de Instâncias (Linhas): 1470
Total de Colunas: 35

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1470 entries, 0 to 1469
Data columns (total 35 columns):
 #   Column                    Non-Null Count  Dtype
 0   Age                       1470 non-null   int64
 1   Attrition                 1470 non-null   object
```

Variável Alvo - Gráfico de Barras (Countplot)

Para problemas de classificação, o primeiro passo gráfico é compreender a distribuição da nossa variável preditiva (`Attrition`).

```
plt.figure(figsize=(6, 4))
ax = sns.countplot(data=df, x='Attrition', palette='Set2')
plt.title('Distribuição da Variável Alvo (Attrition)', fontsize=14)
plt.ylabel('Quantidade de Funcionários')
plt.xlabel('Saiu da Empresa?')

# Adiciono abaixo os rótulos de dados nas barras
for p in ax.patches:
    ax.annotate(f'{p.get_height()}', (p.get_x() + p.get_width() / 2., p.get_height()), ha='center', va='bottom')

plt.show()
```

```
 27  StockOptionLevel          1470 non-null   int64
```

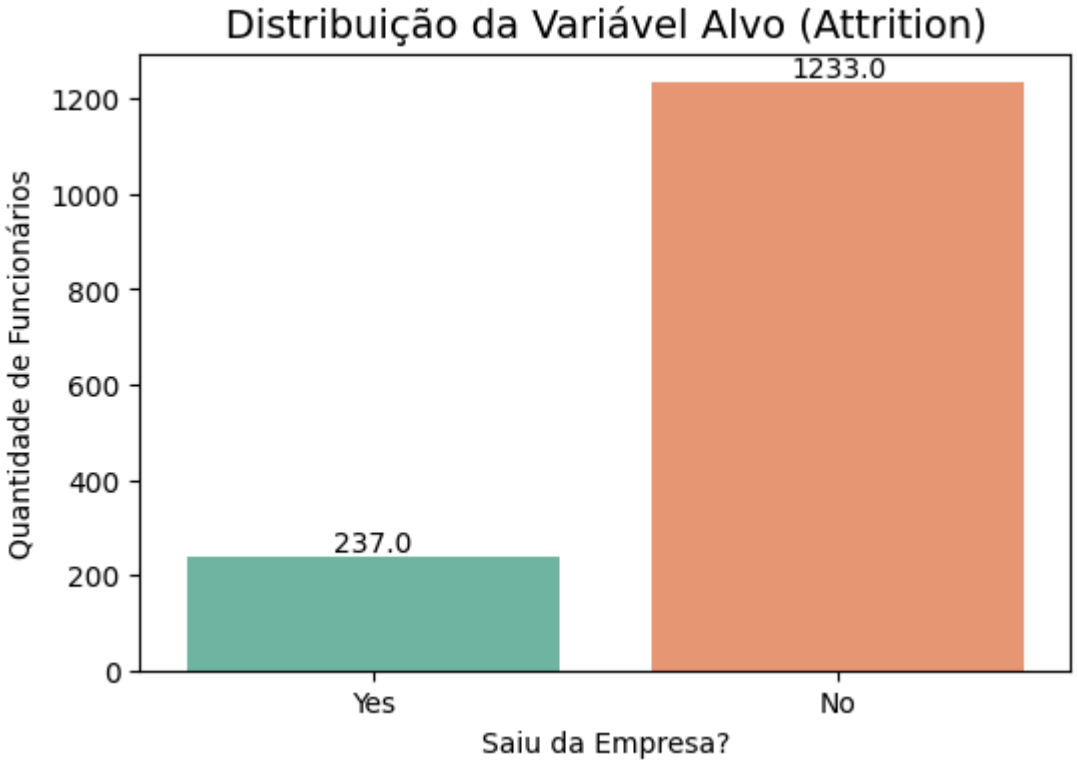

Resultado identificado: O gráfico evidencia que de 1233 funcionários, apenas 237 deixaram a empresa. Isto confirma que o nosso conjunto de dados é **altamente desbalanceado**. Em futuras modelagens de *Machine Learning*, acredito que será crucial aplicar

técnicas como SMOTE ou ajustar os pesos das classes para que o modelo não crie um viés preditivo virado apenas para o 'No'.

Estatísticas Descritivas

Extraí as principais métricas estatísticas (média, desvio padrão, mínimo, máximo, quartis) globais e, em seguida, as estatísticas agrupadas pela variável alvo para traçar paralelos de comportamento.

```
cols_interesse = ['Age', 'MonthlyIncome', 'DistanceFromHome', 'YearsAtCompany']

print("\n--- Estatísticas Descritivas Gerais ---")
display(df[cols_interesse].describe())

print("\n--- Médias Agrupadas pela Variável Alvo (Attrition) ---")
display(df.groupby('Attrition')[cols_interesse].mean())
```

```
--- Estatísticas Descritivas Gerais ---
```

	Age	MonthlyIncome	DistanceFromHome	YearsAtCompany
count	1470.000000	1470.000000	1470.000000	1470.000000
mean	36.923810	6502.931293	9.192517	7.008163
std	9.135373	4707.956783	8.106864	6.126525
min	18.000000	1009.000000	1.000000	0.000000
25%	30.000000	2911.000000	2.000000	3.000000
50%	36.000000	4919.000000	7.000000	5.000000
75%	43.000000	8379.000000	14.000000	9.000000
max	60.000000	19999.000000	29.000000	40.000000

```
--- Médias Agrupadas pela Variável Alvo (Attrition) ---
```

Attrition	Age	MonthlyIncome	DistanceFromHome	YearsAtCompany
No	37.561233	6832.739659	8.915653	7.369019
Yes	33.607595	4787.092827	10.632911	5.130802

Gráfico para Média e Desvio Padrão

Aplicação do modelo: *Qual seria o gráfico mais interessante para mostrar a média e o desvio padrão dos atributos numéricos?*
Resultado: Como as variáveis possuem grandezas matemáticas muito diferentes (a 'Idade' varia em dezenas, enquanto a 'Renda Mensal' chega aos milhares), o gráfico mais interessante é o **Gráfico de Barras com Escala Logarítmica no eixo Y**. Isto me permite visualizar lado a lado variáveis pequenas e gigantes. Adicionamos ainda as barras de erro para representar o desvio padrão diretamente no mesmo visual.

```
plt.figure(figsize=(10, 5))
# O sns.barplot por padrão traça a média e a barra preta representa o desvio padrão (errorbar='sd')
sns.barplot(data=df[cols_interesse], palette='viridis', errorbar='sd', capsize=0.1)
plt.title('Média e Desvio Padrão dos Atributos Numéricos (Escala Log)', fontsize=14)
plt.ylabel('Valor (Escala Logarítmica)')
plt.yscale('log')
plt.show()
```

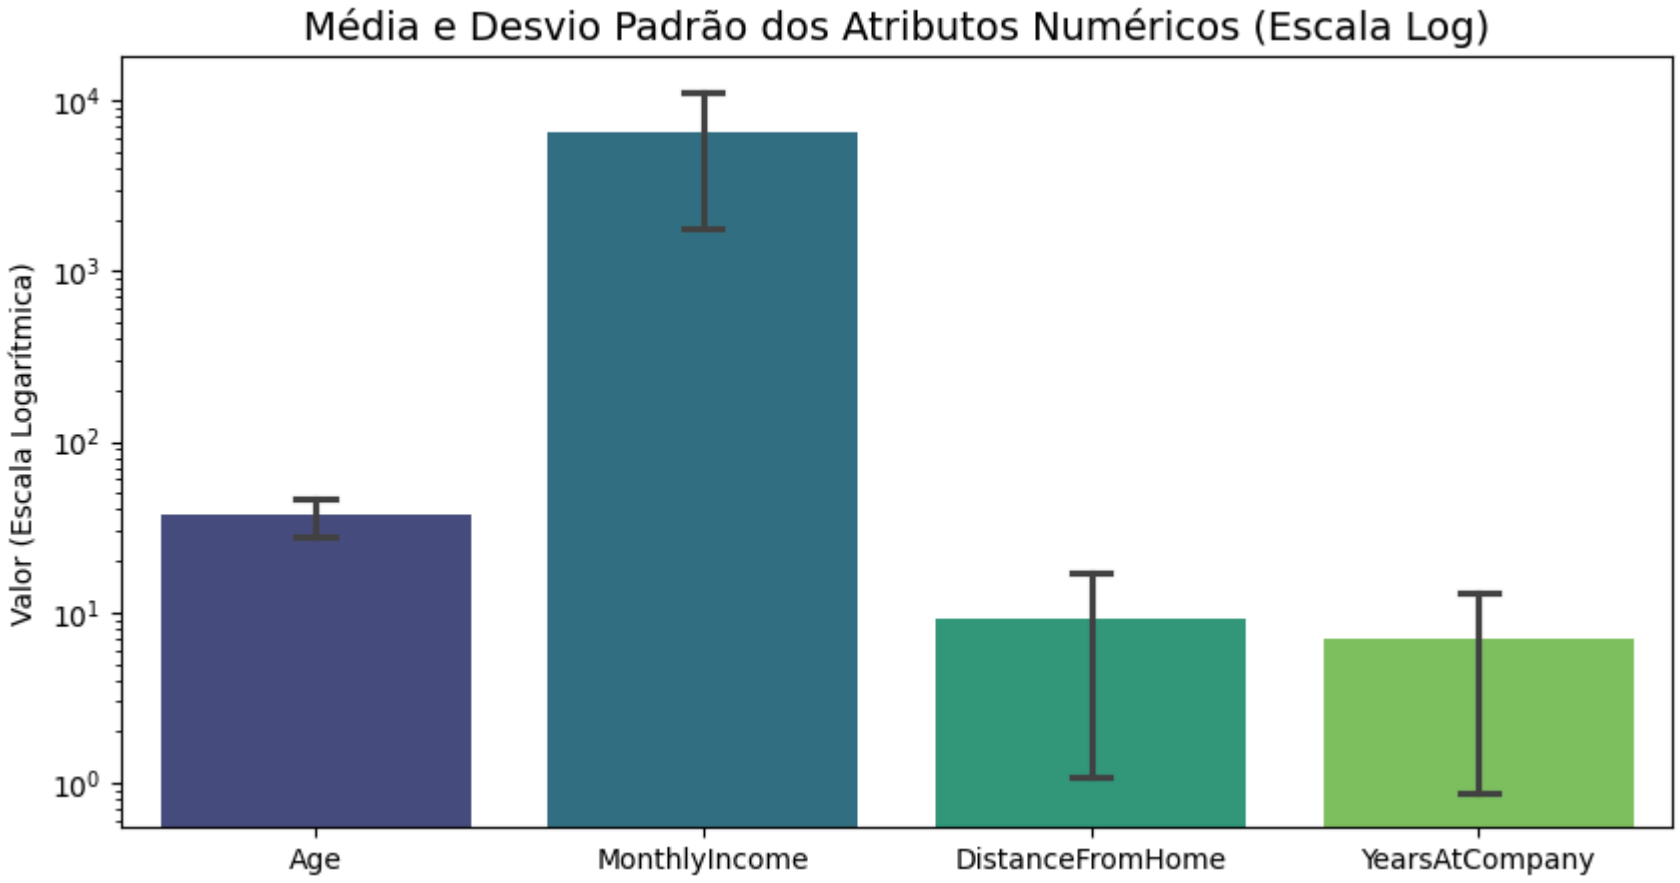

Histogramas com Curva de Densidade (KDE)

Acredito ser essencial para visualizar a distribuição, frequência e assimetria das variáveis numéricas originais.

```
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

sns.histplot(df, x="Age", kde=True, ax=axes[0], color='skyblue')
axes[0].set_title('Distribuição de Idade com KDE')

sns.histplot(df, x="MonthlyIncome", kde=True, ax=axes[1], color='salmon')
axes[1].set_title('Distribuição da Renda Mensal com KDE')

plt.tight_layout()
plt.show()
```

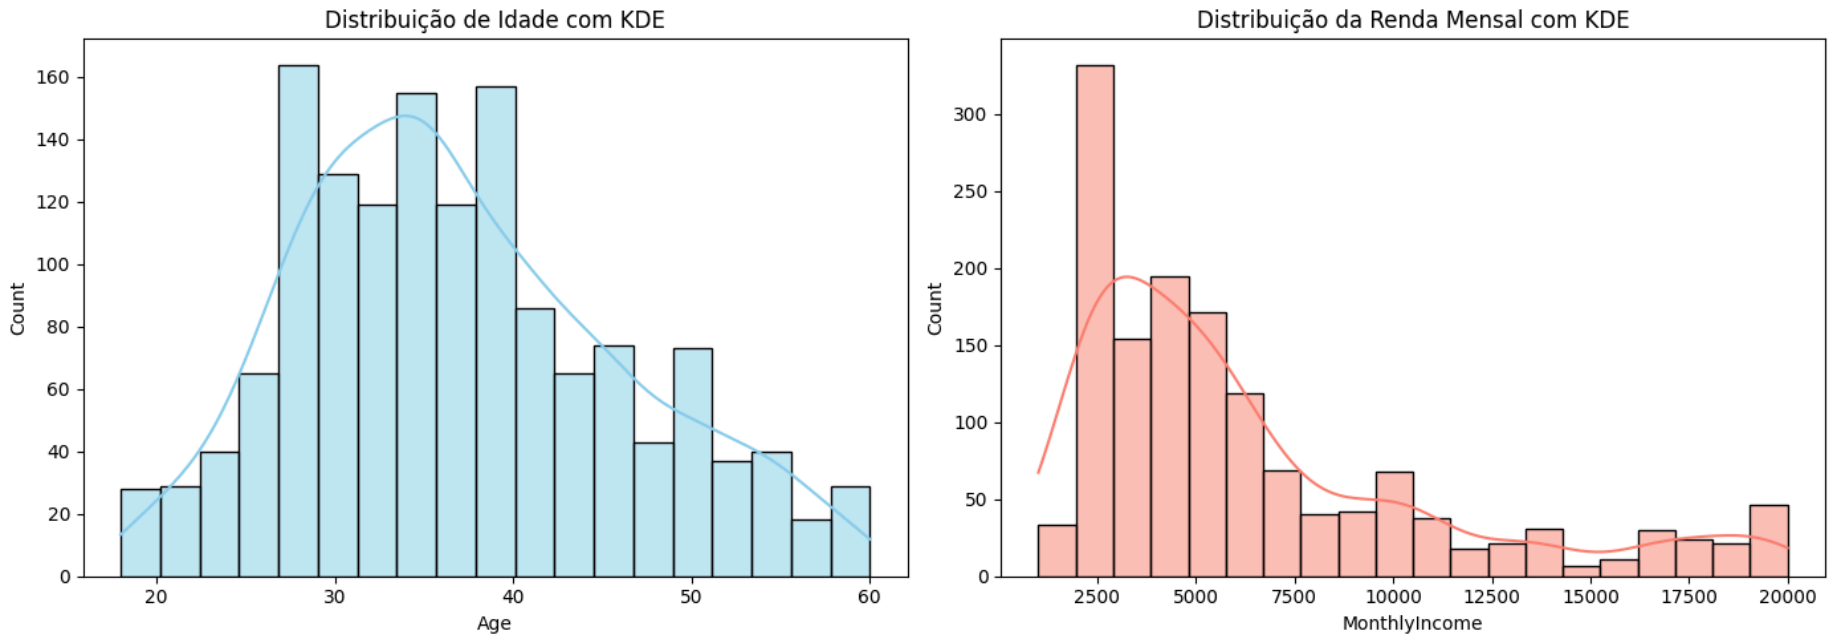

Resultado: A Idade possui uma distribuição que se aproxima de uma curva normal (sino), levemente assimétrica à direita. Já a Renda Mensal possui uma fortíssima assimetria positiva (cauda longa à direita), indicando que a grande massa de funcionários ganha salários mais baixos, com poucos executivos a ganhar altos valores. Isto justifica a necessidade de normalização posterior.

Boxplots Agrupados

Gosto do modelo para comparar a distribuição, as medianas e identificar *outliers* de uma variável numérica dividida pelas categorias da variável alvo.

```
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

sns.boxplot(data=df, x='Attrition', y='MonthlyIncome', palette='Set1', ax=axes[0])
axes[0].set_title('Renda Mensal Agrupada por Attrition')

sns.boxplot(data=df, x='Attrition', y='Age', palette='Set2', ax=axes[1])
axes[1].set_title('Idade Agrupada por Attrition')

plt.tight_layout()
plt.show()
```

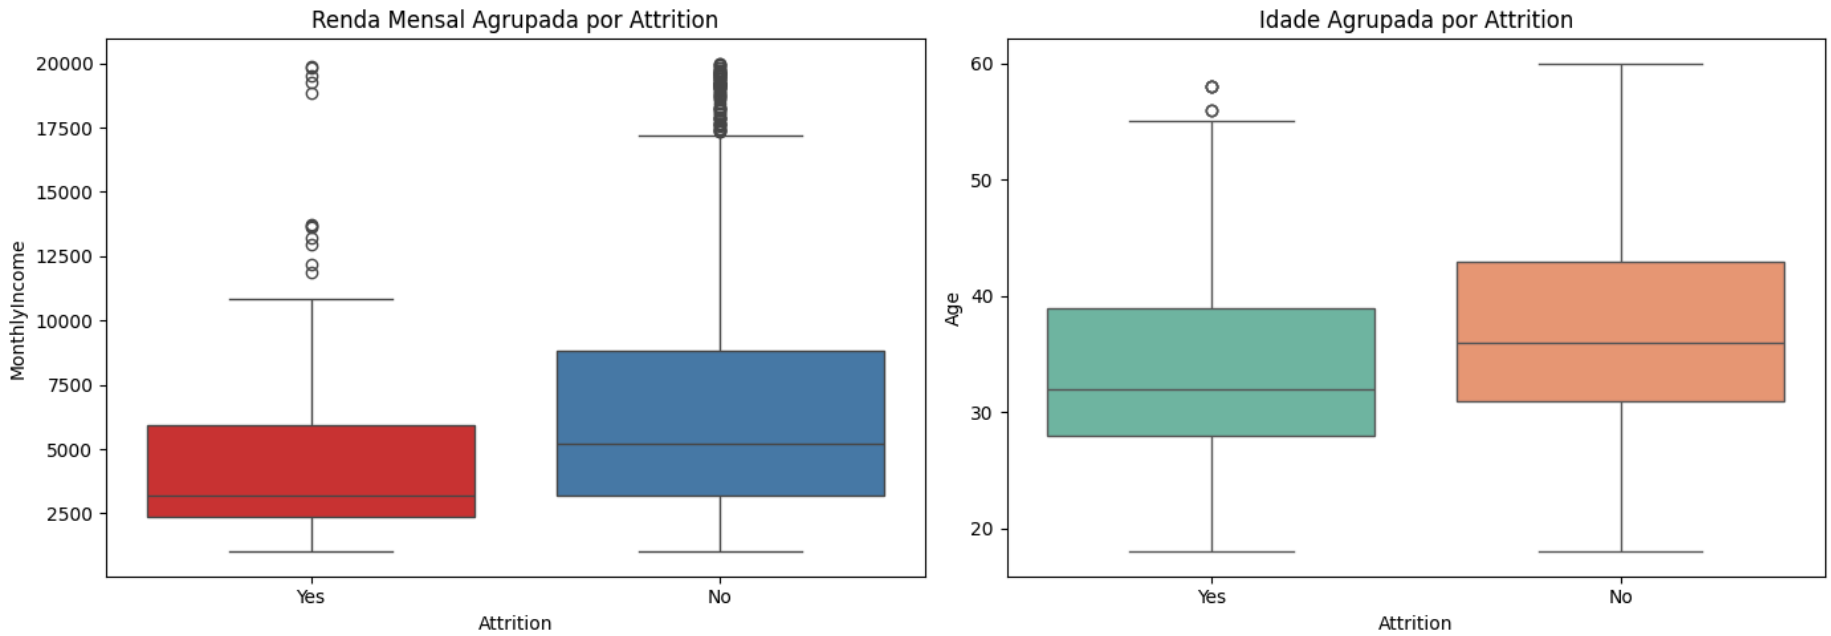

Mapa de Calor (Heatmap) da Matriz de Correlação

Ilustra visualmente a força e a direção da relação linear entre os atributos numéricos.

```
plt.figure(figsize=(12, 10))
# Filtro apenas para variáveis úteis numéricas
num_cols = df.select_dtypes(include=['int64', 'float64']).columns
cols_to_drop = ['EmployeeCount', 'StandardHours', 'EmployeeNumber']
```

```
num_cols = [c for c in num_cols if c not in cols_to_drop]

correlacao = df[num_cols].corr()
mascara = np.triu(np.ones_like(correlacao, dtype=bool))

sns.heatmap(correlacao, mask=mascara, cmap='coolwarm', annot=False, linewidths=.5)
plt.title('Matriz de Correlação (Heatmap)', fontsize=15)
plt.show()
```

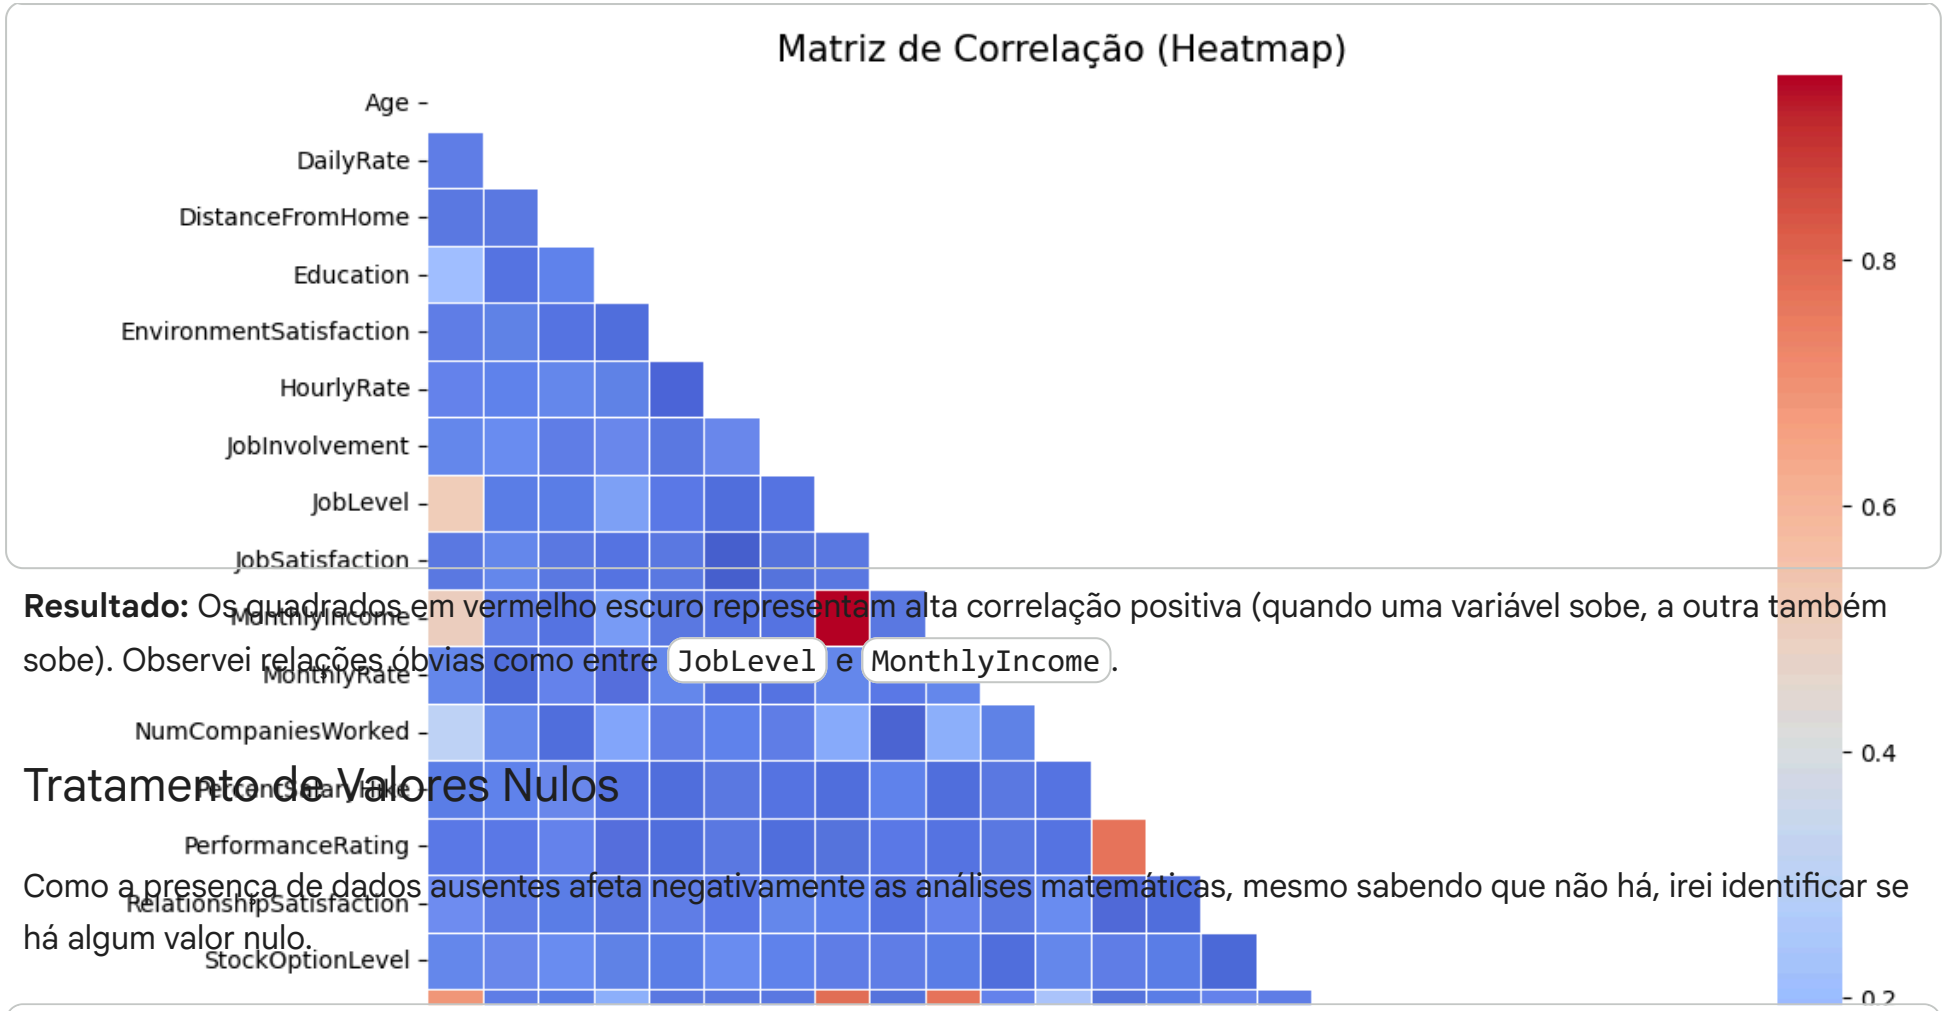

Resultado: Os quadrados em vermelho escuro representam alta correlação positiva (quando uma variável sobe, a outra também sobe). Observei relações óbvias como entre `JobLevel` e `MonthlyIncome`.

Tratamento de Valores Nulos

Como a presença de dados ausentes afeta negativamente as análises matemáticas, mesmo sabendo que não há, irei identificar se há algum valor nulo.

```
print("Total absoluto de valores nulos:", df.isnull().sum().sum())

plt.figure(figsize=(10, 3))
msno.matrix(df, figsize=(10,3), sparkline=False, fontsize=10, color=(0.2, 0.4, 0.6))
plt.title('Matriz de Integridade (Valores Nulos)', fontsize=14)
plt.show()
```

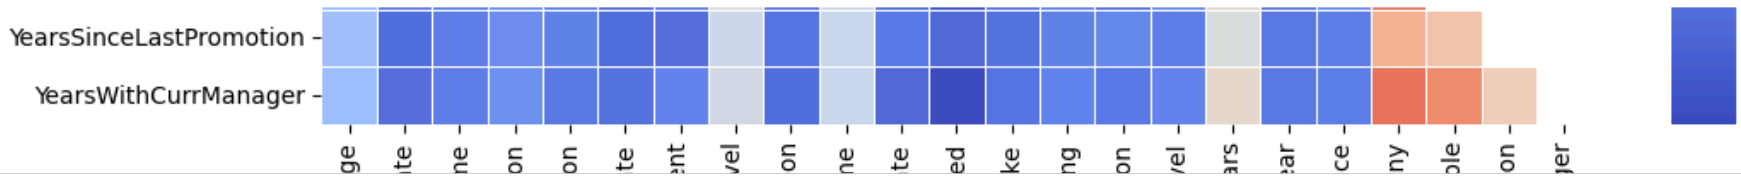

```
Total absoluto de valores nulos: 0
<Figure size 1000x300 with 0 Axes>
```

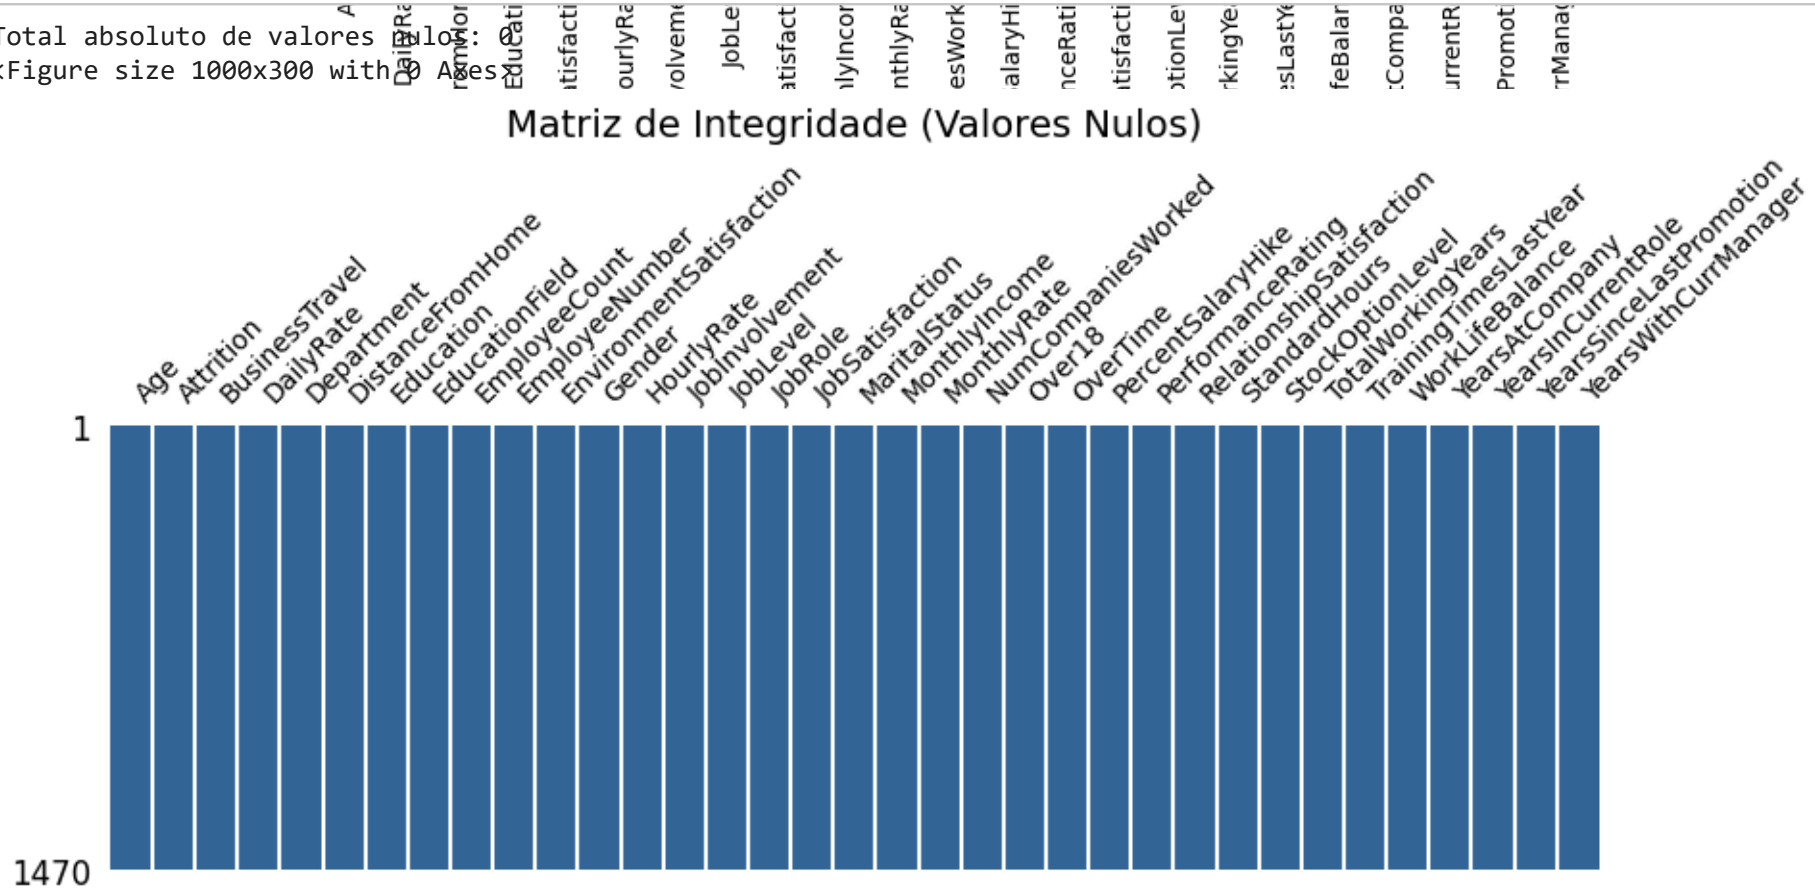

Resultado: A matriz que gerei confirma, como mencionado inicialmente, que o *dataset* está 100% íntegro, ou seja, sem valores nulos. Não há necessidade de realizar técnicas de imputação (preenchimento com média/mediana) ou remoção de linhas (*dropna*).

10. Pré-Processamento de Dados Aqui preparei a base para os algoritmos. Isto envolve:
11. Excluir colunas de variância zero (não agregam).
12. Transformar textos categóricos em numéricos (*Encoding*).
13. Separar as variáveis preditoras (X) da variável alvo (y).
14. Dividir num conjunto de Treino e Teste.

Observação: Para o próximo MVP de Machine Learning, uma etapa crucial que adicionarei aqui é a **Seleção de Características (Feature Selection)** usando técnicas como *Random Forest Feature Importance* para remover variáveis pouco preditivas, ou **Redução de Dimensionalidade (PCA)** para otimizar o tempo de processamento dos modelos.

```
# 1. Remoção de colunas estáticas/IDs
df_clean = df.drop(['EmployeeCount', 'StandardHours', 'Over18', 'EmployeeNumber'], axis=1)

# 2. Separação de X (Preditoras) e y (Alvo)
X = df_clean.drop('Attrition', axis=1)
y = df_clean['Attrition'].map({'Yes': 1, 'No': 0})

# 3. Encoding das variáveis categóricas para o formato binário numérico
X_encoded = pd.get_dummies(X, drop_first=True)

# 4. Divisão em Treino e Teste (80% / 20%) mantendo a proporção das classes (stratify)
X_train, X_test, y_train, y_test = train_test_split(X_encoded, y, test_size=0.2, random_state=42, stratify=y)

print("Shape do X_train:", X_train.shape)
print("Shape do X_test:", X_test.shape)
```

```
Shape do X_train: (1176, 44)
Shape do X_test: (294, 44)
```

Normalização e Padronização + Histogramas Pós-Transformação

Modelos matemáticos baseados em distâncias (KNN, SVM) ou redes neuronais são sensíveis à escala dos dados.

- A **Normalização (MinMaxScaler)** comprime os dados num intervalo fixo (ex: 0 a 1).
- A **Padronização (StandardScaler)** centraliza a média em 0 e ajusta o desvio padrão para 1.

```
# Aplicando MinMaxScaler e StandardScaler na coluna 'MonthlyIncome' para fins didáticos de visualização
min_max = MinMaxScaler()
std_scaler = StandardScaler()
```

```
renda_original = df[['MonthlyIncome']]
renda_norm = min_max.fit_transform(renda_original)
renda_std = std_scaler.fit_transform(renda_original)

# Visualização: Histogramas Pós-Transformação
fig, axes = plt.subplots(1, 3, figsize=(18, 5))

sns.histplot(renda_original, kde=True, ax=axes[0], color='gray', legend=False)
axes[0].set_title('Original (Escala em Milhares)')

sns.histplot(renda_norm, kde=True, ax=axes[1], color='blue', legend=False)
axes[1].set_title('Normalizado (MinMaxScaler: 0 a 1)')

sns.histplot(renda_std, kde=True, ax=axes[2], color='green', legend=False)
axes[2].set_title('Padronizado (StandardScaler: Média=0, Std=1)')

plt.tight_layout()
plt.show()
```

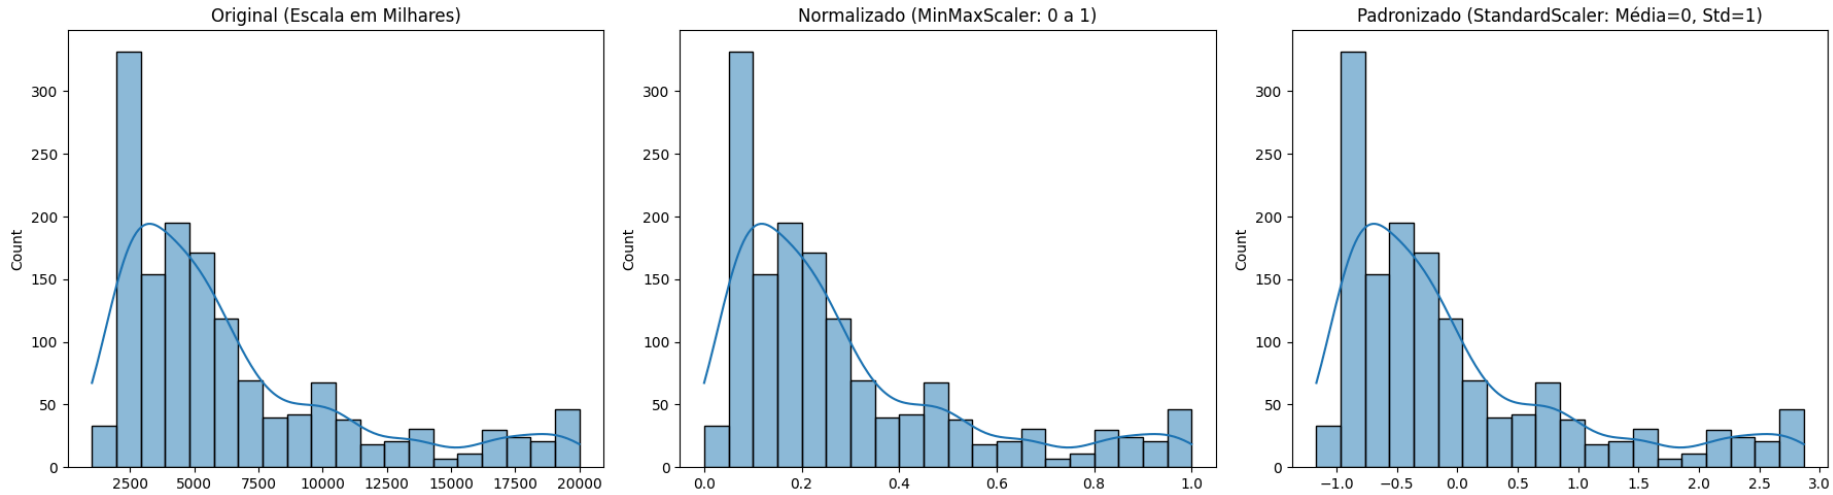

Resultado: Observei que as três distribuições possuem exatamente a mesma curva (formato), o que muda radicalmente é o Eixo X (a escala numérica). A normalização estreitou tudo entre 0 e 1, enquanto a padronização colocou o "pico" do sino em zero.

Comparação de Modelos e Avaliação das Transformações (Pipelines)

Nesta etapa avançada, utilizei a técnica de **Cross-Validation (Validação Cruzada)** e **Pipelines** para testar múltiplos algoritmos de *Machine Learning* em três cenários diferentes:

1. **Dataset Original:** Sem transformação matemática.
2. **Dataset Normalizado:** Escalonado entre 0 e 1.
3. **Dataset Padronizado:** Ajustado para média 0 e desvio padrão 1.

```
np.random.seed(7) # Definindo uma semente global para garantir reprodutibilidade

# Definindo os parâmetros de controle
num_trees = 100
max_features = 3
kfold = KFold(n_splits=10, random_state=7, shuffle=True)
scoring = 'accuracy' # Métrica de avaliação

# Bases para os modelos Ensemble
base = DecisionTreeClassifier()
bases = [
    ('LR', LogisticRegression(max_iter=200)),
    ('KNN', KNeighborsClassifier()),
    ('CART', DecisionTreeClassifier())
]

# Listas para armazenar os pipelines e resultados
pipelines = []
results = []
names = []

# Elementos (Algoritmos) do pipeline
reg_log = ('LR', LogisticRegression(max_iter=200))
knn = ('KNN', KNeighborsClassifier())
cart = ('CART', DecisionTreeClassifier())
naive_bayes = ('NB', GaussianNB())
svm = ('SVM', SVC())
bagging = ('Bag', BaggingClassifier(estimator=base, n_estimators=num_trees))
random_forest = ('RF', RandomForestClassifier(n_estimators=num_trees, max_features=max_features))
extra_trees = ('ET', ExtraTreesClassifier(n_estimators=num_trees, max_features=max_features))
adaboost = ('Ada', AdaBoostClassifier(n_estimators=num_trees))
```

```
gradient_boosting = ('GB', GradientBoostingClassifier(n_estimators=num_trees))
voting = ('Voting', VotingClassifier(bases))

# Elementos (Transformações)
standard_scaler = ('StandardScaler', StandardScaler())
min_max_scaler = ('MinMaxScaler', MinMaxScaler())

# Montando os pipelines - 1. Original
pipelines.append(('LR-orig', Pipeline([reg_log])))
pipelines.append(('KNN-orig', Pipeline([knn])))
pipelines.append(('CART-orig', Pipeline([cart])))
pipelines.append(('NB-orig', Pipeline([naive_bayes])))
pipelines.append(('SVM-orig', Pipeline([svm])))
pipelines.append(('Bag-orig', Pipeline([bagging])))
pipelines.append(('RF-orig', Pipeline([random_forest])))
pipelines.append(('ET-orig', Pipeline([extra_trees])))
pipelines.append(('Ada-orig', Pipeline([adaboost])))
pipelines.append(('GB-orig', Pipeline([gradient_boosting])))
pipelines.append(('Vot-orig', Pipeline([voting])))

# Montando os pipelines - 2. Padronizado
pipelines.append(('LR-padr', Pipeline([standard_scaler, reg_log])))
pipelines.append(('KNN-padr', Pipeline([standard_scaler, knn])))
```